# 넷째마당
# 딥러닝 기본기 다지기

# 15장 실제 데이터로 만들어 보는 모델

1 데이터 파악하기

2 결측치, 카테고리 변수 처리하기

3 속성별 관련도 추출하기

4 주택 가격 예측 모델

# 실제 데이터로 만들어 보는 모델

- 실제 데이터로 만들어 보는 모델

# 실제 데이터로 만들어 보는 모델

- **실제 데이터로 만들어 보는 모델**
  - 지금까지 한 실습은 참 또는 거짓을 맞히거나 여러 개의 보기 중 하나를 예측하는 분류 문제
  - 이번에는 수치를 예측하는 문제
  - 준비된 데이터는 아이오와주 에임스 지역에서 2006년부터 2010년까지 거래된 실제 부동산 판매 기록
  - 주거 유형, 차고, 자재 및 환경에 관한 80개의 서로 다른 속성을 이용해 집의 가격을 예측해 볼 예정
  - 오랜 시간 사람이 일일이 기록하다 보니 빠진 부분도 많고, 집에 따라 어떤 항목은 범위에서 너무 벗어나 있기도 하며, 또 가격과는 관계가 없는 정보가 포함되어 있기도 함
  - 실제 현장에서 만나게 되는 이런 류의 데이터를 어떻게 다루어야 하는지 이 장에서 학습해 보자

# 1 데이터 파악하기

# 1 데이터 파악하기

- **데이터 파악하기**
  - 먼저 데이터를 불러와 확인해 보자

```
import pandas as pd

# 깃허브에 준비된 데이터를 가져옵니다.
!git clone https://github.com/taehojo/data.git

# 집 값 데이터를 불러옵니다.
df = pd.read_csv("./data/house_train.csv")
```

# 1 데이터 파악하기

- **데이터 파악하기**
  - 데이터를 미리 살펴보자

```
df
```

# 1 데이터 파악하기

- 데이터 파악하기

실행 결과

| | Id | MSSubClass | MSZoning | LotFrontage | LotArea | Street | Alley | LotShape | LandContour | Utilities | ... |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 1 | 60 | RL | 65.0 | 8450 | Pave | NaN | Reg | Lvl | AllPub | ... |
| 1 | 2 | 20 | RL | 80.0 | 9600 | Pave | NaN | Reg | Lvl | AllPub | ... |
| 2 | 3 | 60 | RL | 68.0 | 11250 | Pave | NaN | IR1 | Lvl | AllPub | ... |
| 3 | 4 | 70 | RL | 60.0 | 9550 | Pave | NaN | IR1 | Lvl | AllPub | ... |
| 4 | 5 | 60 | RL | 84.0 | 14260 | Pave | NaN | IR1 | Lvl | AllPub | ... |
| ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... |
| 1455 | 1456 | 60 | RL | 62.0 | 7917 | Pave | NaN | Reg | Lvl | AllPub | ... |
| 1456 | 1457 | 20 | RL | 85.0 | 13175 | Pave | NaN | Reg | Lvl | AllPub | ... |
| 1457 | 1458 | 70 | RL | 66.0 | 9042 | Pave | NaN | Reg | Lvl | AllPub | ... |
| 1458 | 1459 | 20 | RL | 68.0 | 9717 | Pave | NaN | Reg | Lvl | AllPub | ... |
| 1459 | 1460 | 20 | RL | 75.0 | 9937 | Pave | NaN | Reg | Lvl | AllPub | ... |

# 1 데이터 파악하기

- 데이터 파악하기

| PoolArea | PoolQC | Fence | MiscFeature | MiscVal | MoSold | YrSold | SaleType | SaleCondition | SalePrice |
|---|---|---|---|---|---|---|---|---|---|
| 0 | NaN | NaN | NaN | 0 | 2 | 2008 | WD | Normal | 208500 |
| 0 | NaN | NaN | NaN | 0 | 5 | 2007 | WD | Normal | 181500 |
| 0 | NaN | NaN | NaN | 0 | 9 | 2008 | WD | Normal | 223500 |
| 0 | NaN | NaN | NaN | 0 | 2 | 2006 | WD | Abnorml | 140000 |
| 0 | NaN | NaN | NaN | 0 | 12 | 2008 | WD | Normal | 250000 |
| ... | ... | ... | ... | ... | ... | ... | ... | ... | ... |
| 0 | NaN | NaN | NaN | 0 | 8 | 2007 | WD | Normal | 175000 |
| 0 | NaN | MnPrv | NaN | 0 | 2 | 2010 | WD | Normal | 210000 |
| 0 | NaN | GdPrv | Shed | 2500 | 5 | 2010 | WD | Normal | 266500 |
| 0 | NaN | NaN | NaN | 0 | 4 | 2010 | WD | Normal | 142125 |
| 0 | NaN | NaN | NaN | 0 | 6 | 2008 | WD | Normal | 147500 |

1460 rows × 81 columns

# 1 데이터 파악하기

- **데이터 파악하기**
  - 총 80개의 속성으로 이루어져 있고 마지막 열이 우리의 타깃인 집 값(SalePrice)
  - 모두 1,460개의 샘플이 들어 있음

# 1 데이터 파악하기

- **데이터 파악하기**
  - 이제 각 데이터가 어떤 유형으로 되어 있는지 알아보자

```
df.dtypes
```

# 1 데이터 파악하기

- 데이터 파악하기

실행 결과

```
Id                int64
MSSubClass        int64
MSZoning         object
LotFrontage     float64
LotArea           int64
            ...
MoSold            int64
YrSold            int64
SaleType         object
SaleCondition    object
SalePrice         int64
Length: 81, dtype: object
```

# 1 데이터 파악하기

- **데이터 파악하기**
  - 정수형(int64)과 실수형(float64), 그리고 오브젝트형(object) 등 여러 유형이 있음을 알 수 있음

# 2 결측치, 카테고리 변수 처리하기

# 2 결측치, 카테고리 변수 처리하기

- **결측치, 카테고리 변수 처리하기**
  - 앞 장에서 다루었던 데이터와 차이점은 아직 전처리가 끝나지 않은 상태의 데이터라 측정 값이 없는 결측치가 있다는 것
  - 결측치가 있는지 알아보는 함수는 isnull()
  - 결측치가 모두 몇 개인지 세어 가장 많은 것부터 순서대로 나열한 후 처음 20개만 출력하는 코드는 다음과 같음

```
df.isnull().sum().sort_values(ascending=False).head(20)
```

# 2 결측치, 카테고리 변수 처리하기

- 결측치, 카테고리 변수 처리하기

실행 결과

```
PoolQC          1453
MiscFeature     1406
Alley           1369
Fence           1179
FireplaceQu      690
LotFrontage      259
GarageYrBlt       81
GarageCond        81
GarageType        81
GarageFinish      81
```

# 2 결측치, 카테고리 변수 처리하기

- 결측치, 카테고리 변수 처리하기

```
GarageQual        81
BsmtFinType2      38
BsmtExposure      38
BsmtQual          37
BsmtCond          37
BsmtFinType1      37
MasVnrArea         8
MasVnrType         8
Electrical         1
Id                 0
dtype: int64
```

# 2 결측치, 카테고리 변수 처리하기

- **결측치, 카테고리 변수 처리하기**
  - 결측치가 많은 항목은 1,460개의 샘플 중에서 1,453개나 비어 있을 만큼 빠진 곳이 많은 것을 확인할 수 있음

# 2 결측치, 카테고리 변수 처리하기

- **결측치, 카테고리 변수 처리하기**
  - 이제 모델을 만들기 위해 데이터를 전처리하겠음
  - 먼저 12.3절에서 소개되었던 판다스의 get_dummies() 함수를 이용해 카테고리형 변수를 0과 1로 이루어진 변수로 바꾸어 줌

```
df = pd.get_dummies(df)
```

# 2 결측치, 카테고리 변수 처리하기

- **결측치, 카테고리 변수 처리하기**
  - 결측치를 채워 줌
  - 결측치를 채워 주는 함수는 판다스의 fillna()
  - 괄호 안에 df.mean()을 넣어 주면 평균값으로 채워 줌

```
df = df.fillna(df.mean())
```

# 2 결측치, 카테고리 변수 처리하기

- **결측치, 카테고리 변수 처리하기**
  - 특정한 값으로 대체하려면 fillna() 함수의 괄호 안에 해당 값을 적으면 됨
  - 예를 들어 결측치를 모두 0으로 바꾸려면 fillna(0)이 됨
  - dropna()를 사용하면 결측치가 있는 속성을 제거
  - 이때 dropna(how='any')는 결측치가 하나라도 있으면 삭제하라는 의미이고, dropna(how='all')은 모든 값이 결측치일 때 삭제하라는 의미

# 2 결측치, 카테고리 변수 처리하기

- **결측치, 카테고리 변수 처리하기**
  - 이제 업데이트된 데이터 프레임을 출력해 보자

```
df
```

# 2 결측치, 카테고리 변수 처리하기

- 결측치, 카테고리 변수 처리하기

실행 결과

| | Id | MSSubClass | LotFrontage | LotArea | OverallQual | OverallCond | YearBuilt | YearRemodAdd | MasVnrArea | BsmtFinSF1 | ... |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 1 | 60 | 65.0 | 8450 | 7 | 5 | 2003 | 2003 | 196.0 | 706 | ... |
| 1 | 2 | 20 | 80.0 | 9600 | 6 | 8 | 1976 | 1976 | 0.0 | 978 | ... |
| 2 | 3 | 60 | 68.0 | 11250 | 7 | 5 | 2001 | 2002 | 162.0 | 486 | ... |
| 3 | 4 | 70 | 60.0 | 9550 | 7 | 5 | 1915 | 1970 | 0.0 | 216 | ... |
| 4 | 5 | 60 | 84.0 | 14260 | 8 | 5 | 2000 | 2000 | 350.0 | 655 | ... |
| ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... | ... |
| 1455 | 1456 | 60 | 62.0 | 7917 | 6 | 5 | 1999 | 2000 | 0.0 | 0 | ... |
| 1456 | 1457 | 20 | 85.0 | 13175 | 6 | 6 | 1978 | 1988 | 119.0 | 790 | ... |
| 1457 | 1458 | 70 | 66.0 | 9042 | 7 | 9 | 1941 | 2006 | 0.0 | 275 | ... |
| 1458 | 1459 | 20 | 68.0 | 9717 | 5 | 6 | 1950 | 1996 | 0.0 | 49 | ... |
| 1459 | 1460 | 20 | 75.0 | 9937 | 5 | 6 | 1965 | 1965 | 0.0 | 830 | ... |

# 2 결측치, 카테고리 변수 처리하기

- 결측치, 카테고리 변수 처리하기

| SaleType_WD | SaleCondition_Abnorml | SaleCondition_AdjLand | SaleCondition_Alloca | SaleCondition_Family | SaleCondition_Normal | SaleCondition_Partial |
|---|---|---|---|---|---|---|
| 1 | 0 | 0 | 0 | 0 | 1 | 0 |
| 1 | 0 | 0 | 0 | 0 | 1 | 0 |
| 1 | 0 | 0 | 0 | 0 | 1 | 0 |
| 1 | 1 | 0 | 0 | 0 | 0 | 0 |
| 1 | 0 | 0 | 0 | 0 | 1 | 0 |
| ... | ... | ... | ... | ... | ... | ... |
| 1 | 0 | 0 | 0 | 0 | 1 | 0 |
| 1 | 0 | 0 | 0 | 0 | 1 | 0 |
| 1 | 0 | 0 | 0 | 0 | 1 | 0 |
| 1 | 0 | 0 | 0 | 0 | 1 | 0 |
| 1 | 0 | 0 | 0 | 0 | 1 | 0 |

1460 rows × 290 columns

- 결측치는 보이지 않으며, 카테고리형 변수를 모두 원-핫 인코딩 처리하므로 전체 열이 81개에서 290개로 늘었음

# 3 속성별 관련도 추출하기

# 3 속성별 관련도 추출하기

- **속성별 관련도 추출하기**
  - 이 중에서 우리에게 필요한 정보를 추출해 보자
  - 먼저❶ 데이터 사이의 상관관계를 df_corr 변수에 저장
  - ❷ 집 값과 관련이 큰 것부터 순서대로 정렬해 df_corr_ sort 변수에 저장
  - ❸ 집 값과 관련도가 가장 큰 열 개의 속성들을 출력

```
df_corr = df.corr() ····· ❶
df_corr_sort = df_corr.sort_values('SalePrice', ascending=False) ····· ❷
df_corr_sort['SalePrice'].head(10) ····· ❸
```

# 3 속성별 관련도 추출하기

- 속성별 관련도 추출하기

실행 결과

```
SalePrice       1.000000
OverallQual     0.790982
GrLivArea       0.708624
GarageCars      0.640409
GarageArea      0.623431
TotalBsmtSF     0.613581
1stFlrSF        0.605852
FullBath        0.560664
BsmtQual_Ex     0.553105
TotRmsAbvGrd    0.533723
Name: SalePrice, dtype: float64
```

# 3 속성별 관련도 추출하기

- **속성별 관련도 추출하기**
  - 추출된 속성들과 집 값의 관련도를 시각적으로 확인하기 위해 상관도 그래프를

```
cols = ['SalePrice','OverallQual','GrLivArea','GarageCars','GarageArea',
'TotalBsmtSF']
sns.pairplot(df[cols])
plt.show();
```

# 3 속성별 관련도 추출하기

- 속성별 관련도 추출하기

실행 결과

▼ 그림 15-1 | 추출된 속성들과 집 값의 관련도

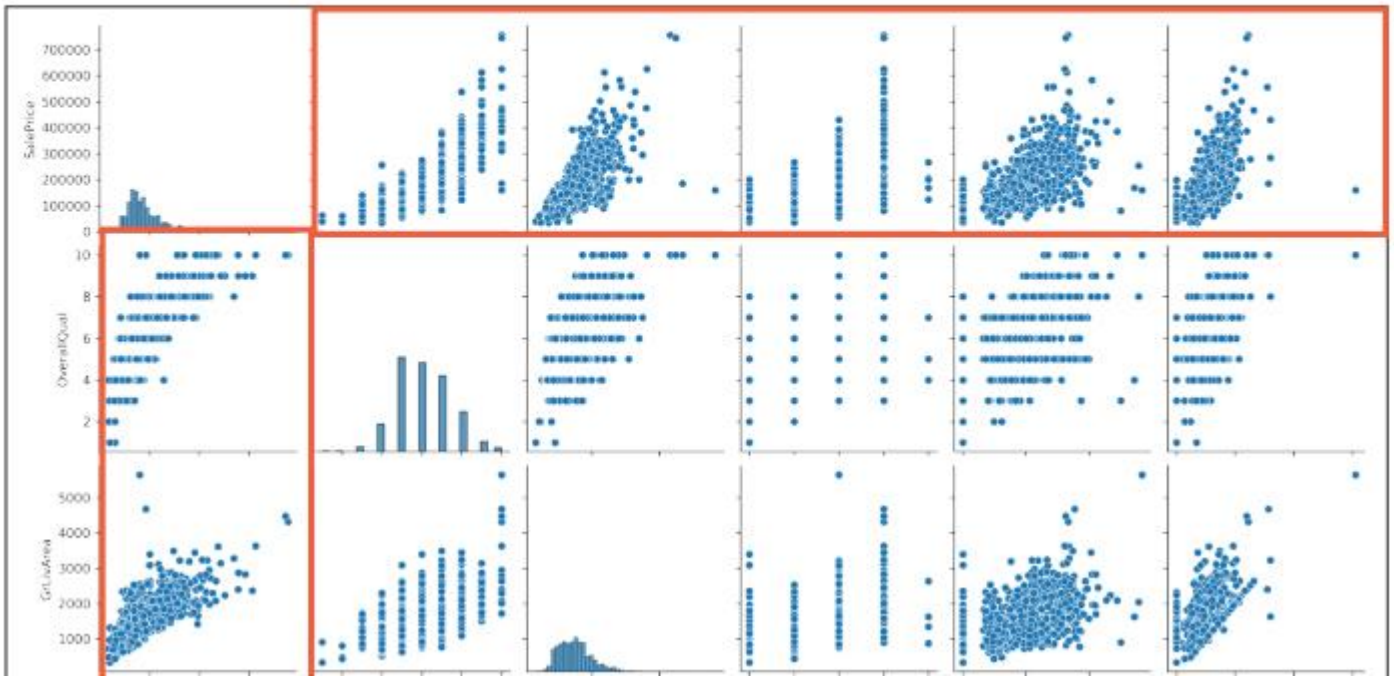

# 3 속성별 관련도 추출하기

- 속성별 관련도 추출하기

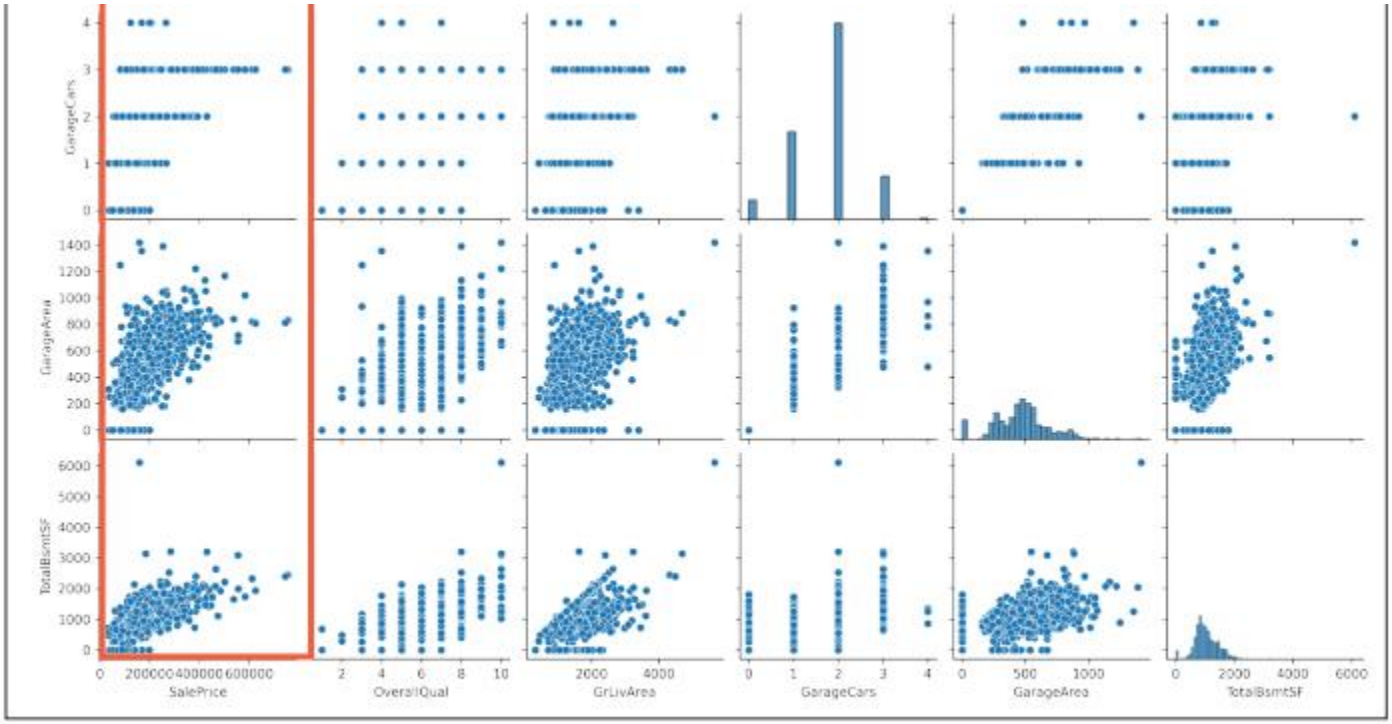


- 선택된 속성들이 집 값(SalePrice)과 양의 상관관계가 있음을 확인할 수 있음(빨간색 사각형으로 표시한 부분)

# 4 주택 가격 예측 모델

# 4 주택 가격 예측 모델

- **주택 가격 예측 모델**
  - 이제 앞서 구한 중요 속성을 이용해 학습셋과 테스트셋을 만들어 보자
  - 집 값을 y로, 나머지 열을 X_train_pre로 저장한 후 전체의 80%를 학습셋으로, 20%를 테스트셋으로 지정

```
cols_train = ['OverallQual','GrLivArea','GarageCars','GarageArea','TotalB
smtSF']
X_train_pre = df[cols_train]
y = df['SalePrice'].values
X_train, X_test, y_train, y_test = train_test_split(X_train_pre, y, test_
size=0.2)
```

# 4 주택 가격 예측 모델

- **주택 가격 예측 모델**
  - 모델의 구조와 실행 옵션을 설정
  - 입력될 속성의 개수를 X_train.shape[1]로 지정해 자동으로 세도록 했음

```
model = Sequential()
model.add(Dense(10, input_dim=X_train.shape[1], activation='relu'))
model.add(Dense(30, activation='relu'))
model.add(Dense(40, activation='relu'))
model.add(Dense(1))
model.summary()
```

# 4 주택 가격 예측 모델

- **주택 가격 예측 모델**
  - 실행에서 달라진 점은 손실 함수
  - 선형 회귀이므로 평균 제곱 오차(mean_squared_error)를 적음

```
model.compile(optimizer='adam', loss='mean_squared_error')
```

# 4 주택 가격 예측 모델

- **주택 가격 예측 모델**
  - 20번 이상 결과가 향상되지 않으면 자동으로 중단되게끔 함
  - 저장될 모델 이름을 'Ch15-house.hdf5'로 정함
  - 모델은 차후 '22장. 캐글로 시작하는 새로운 도전'에서 다시 사용(검증셋을 추가하고 싶을 경우 앞서와 마찬가지로 학습셋, 검증셋, 테스트셋의 비율을 각각 60%, 20%, 20%로 정하면 됨)

```
early_stopping_callback = EarlyStopping(monitor='val_loss', patience=20)

modelpath = "./data/model/Ch15-house.hdf5"

checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val_loss',
verbose=0, save_best_only=True)

history = model.fit(X_train, y_train, validation_split=0.25, epochs=2000,
batch_size=32, callbacks=[early_stopping_callback,checkpointer])
```

# 4 주택 가격 예측 모델

- **주택 가격 예측 모델**
  - 모든 코드를 실행하면 다음과 같음

**실습 | 주택 가격 예측하기**

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
from tensorflow.keras.callbacks import EarlyStopping
from sklearn.model_selection import train_test_split

import matplotlib.pyplot as plt
import seaborn as sns

import pandas as pd
import numpy as np
```

# 4 주택 가격 예측 모델

- 주택 가격 예측 모델

```
# 깃허브에 준비된 데이터를 가져옵니다.

!git clone https://github.com/taehojo/data.git

# 집 값 데이터를 불러옵니다.
df = pd.read_csv("./data/house_train.csv")

# 카테고리형 변수를 0과 1로 이루어진 변수로 바꾸어 줍니다.
df = pd.get_dummies(df)

# 결측치를 전체 칼럼의 평균으로 대체해 채워 줍니다.
df = df.fillna(df.mean())
```

# 4 주택 가격 예측 모델

- 주택 가격 예측 모델

```
# 데이터 사이의 상관관계를 저장합니다.
df_corr = df.corr()

# 집 값과 관련이 큰 것부터 순서대로 저장합니다.
df_corr_sort = df_corr.sort_values('SalePrice', ascending=False)

# 집 값을 제외한 나머지 열을 저장합니다.
cols_train = ['OverallQual','GrLivArea','GarageCars','GarageArea','TotalB
smtSF']
X_train_pre = df[cols_train]

# 집 값을 저장합니다.
y = df['SalePrice'].values
```

# 4 주택 가격 예측 모델

- 주택 가격 예측 모델

```
# 전체의 80%를 학습셋으로, 20%를 테스트셋으로 지정합니다.
X_train, X_test, y_train, y_test = train_test_split(X_train_pre, y, test_
size=0.2)

# 모델의 구조를 설정합니다.
model = Sequential()
model.add(Dense(10, input_dim=X_train.shape[1], activation='relu'))
model.add(Dense(30, activation='relu'))
model.add(Dense(40, activation='relu'))
model.add(Dense(1))
model.summary()
```

# 4 주택 가격 예측 모델

- 주택 가격 예측 모델

```
# 모델을 실행합니다.
model.compile(optimizer='adam', loss='mean_squared_error')

# 20번 이상 결과가 향상되지 않으면 자동으로 중단되게끔 합니다.
early_stopping_callback = EarlyStopping(monitor='val_loss', patience=20)

# 모델의 이름을 정합니다.
modelpath = "./data/model/Ch15-house.hdf5"

# 최적화 모델을 업데이트하고 저장합니다.
checkpointer = ModelCheckpoint(filepath=modelpath, monitor='val_loss',
verbose=0, save_best_only=True)
```

# 4 주택 가격 예측 모델

- 주택 가격 예측 모델

```
# 실행 관련 설정을 하는 부분입니다. 전체의 20%를 검증셋으로 설정합니다.
history = model.fit(X_train, y_train, validation_split=0.25, epochs=2000,
batch_size=32, callbacks=[early_stopping_callback,checkpointer])
```

# 4 주택 가격 예측 모델

- 주택 가격 예측 모델

실행 결과

```
Model: "sequential"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
dense (Dense)                (None, 10)                60
_________________________________________________________________
dense_1 (Dense)              (None, 30)                330
_________________________________________________________________
dense_2 (Dense)              (None, 40)                1240
_________________________________________________________________
dense_3 (Dense)              (None, 1)                 41
=================================================================
```

# 4 주택 가격 예측 모델

- 주택 가격 예측 모델

```
Total params: 1,671
Trainable params: 1,671
Non-trainable params: 0
_____________________________________________________________
Epoch 1/2000
28/28 [==============================] - 0s 5ms/step - loss:
39256875008.0000 - val_loss: 38050066432.0000
... (중략) ...
Epoch 145/2000
28/28 [==============================] - 0s 2ms/step - loss:
1962943104.0000 - val_loss: 2011970944.0000
```

- 145번째에서 학습이 중단

# 4 주택 가격 예측 모델

- **주택 가격 예측 모델**
  - 학습 중단 시점은 실행할 때마다 다를 수 있음

# 4 주택 가격 예측 모델

- **주택 가격 예측 모델**
  - 학습 결과를 시각화하기 위해 예측 값과 실제 값, 실행 번호가 들어갈 빈 리스트를 만들고 25개의 샘플로부터 얻은 결과를 채워 넣겠음

```
real_prices = []
pred_prices = []
X_num = []

n_iter = 0
Y_prediction = model.predict(X_test).flatten()
for i in range(25):
    real = y_test[i]
    prediction = Y_prediction[i]
    print("실제가격: {:.2f}, 예상가격: {:.2f}".format(real, prediction))
    real_prices.append(real)
```

# 4 주택 가격 예측 모델

- 주택 가격 예측 모델

```
pred_prices.append(prediction)
n_iter = n_iter + 1
X_num.append(n_iter)
```

# 4 주택 가격 예측 모델

- 주택 가격 예측 모델

실행 결과

```
실제가격: 262500.00, 예상가격: 240051.36
실제가격: 78000.00, 예상가격: 118369.56
... (중략) ...
실제가격: 127000.00, 예상가격: 116693.46
실제가격: 485000.00, 예상가격: 357789.88
```

# 4 주택 가격 예측 모델

- **주택 가격 예측 모델**
  - 그래프를 통해 샘플로 뽑은 25개의 값을 비교해 보자

```
plt.plot(X_num, pred_prices, label='predicted price')
plt.plot(X_num, real_prices, label='real price')
plt.legend()
plt.show()
```

# 4 주택 가격 예측 모델

- 주택 가격 예측 모델

실행 결과

▼ 그림 15-2 | 실제 집 값과 예측된 집 값 비교

# 4 주택 가격 예측 모델

- **주택 가격 예측 모델**
  - 예측된 집 값의 곡선이 실제 집 값의 곡선과 유사하게 움직이고 있음을 볼 수 있음
  - 그림 15-2에 출력되는 곡선의 전체적인 형태는 실행할 때마다 달라질 수 있음
  - 예측된 집 값의 곡선과 실제 집 값의 곡선이 유사하게 움직이면 잘 학습된 것